Deliverable 1 — Data Mastery Groupe 5 · Case 2 ML Segmentation · 27 mars 2026

399,997 lignes	64,469 clients	184,282 tickets	Jan → Déc 2025	France 98.6%

A Grain de la table

1 ligne = 1 article acheté. Pour la segmentation on agrège en **1 ligne par client × 25 features** (RFM + diversité marques + canal + discount + tendance).

Niveau	Cardinalité	Rôle
Article (source)	399,997	Donnée brute
Ticket (panier)	184,282	Calcul panier moyen
Client (cible ML)	64,469	Entrée clustering

B Qualité des données — 5 anomalies corrigées

#	Anomalie	Impact	Correction
①	Typo « MAEK UP »	115,679 lignes (29%)	→ MAKE UP
②	age_category manquant	28% des clients	Imputation post-cluster
③	Tranche 36-45 ans absente	Analyse génération impossible	Flag unknown_36_45
④	IDs en notation scientifique	100% des lignes	dtype=str forcé
⑤	age = 0 partout	34 419 lignes inutilisables	Ignoré → age_category

C Chiffres clés

CA total 2025	**12.77M EUR**
Panier moyen / ticket	**69.31 EUR**
Fréquence moy. / client	**3.00 tickets**
Recency moyenne	**111 jours**
Discount rate global	**13.1%**
Taux omnicanaux	**12.5% (+182% CA)**
Clients mono-achat	**44.7% (×3.9 CLV si fidél**
Hommes — découverte	**Panier +37% vs femmes (91€ vs 67€)**

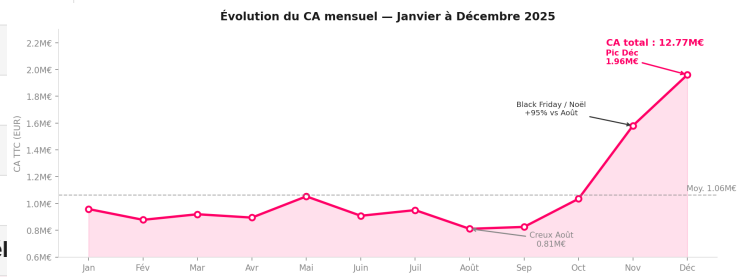

Évolution CA mensuel (gauche) · Heatmap marques × axes produit (ci-dessous — k€)

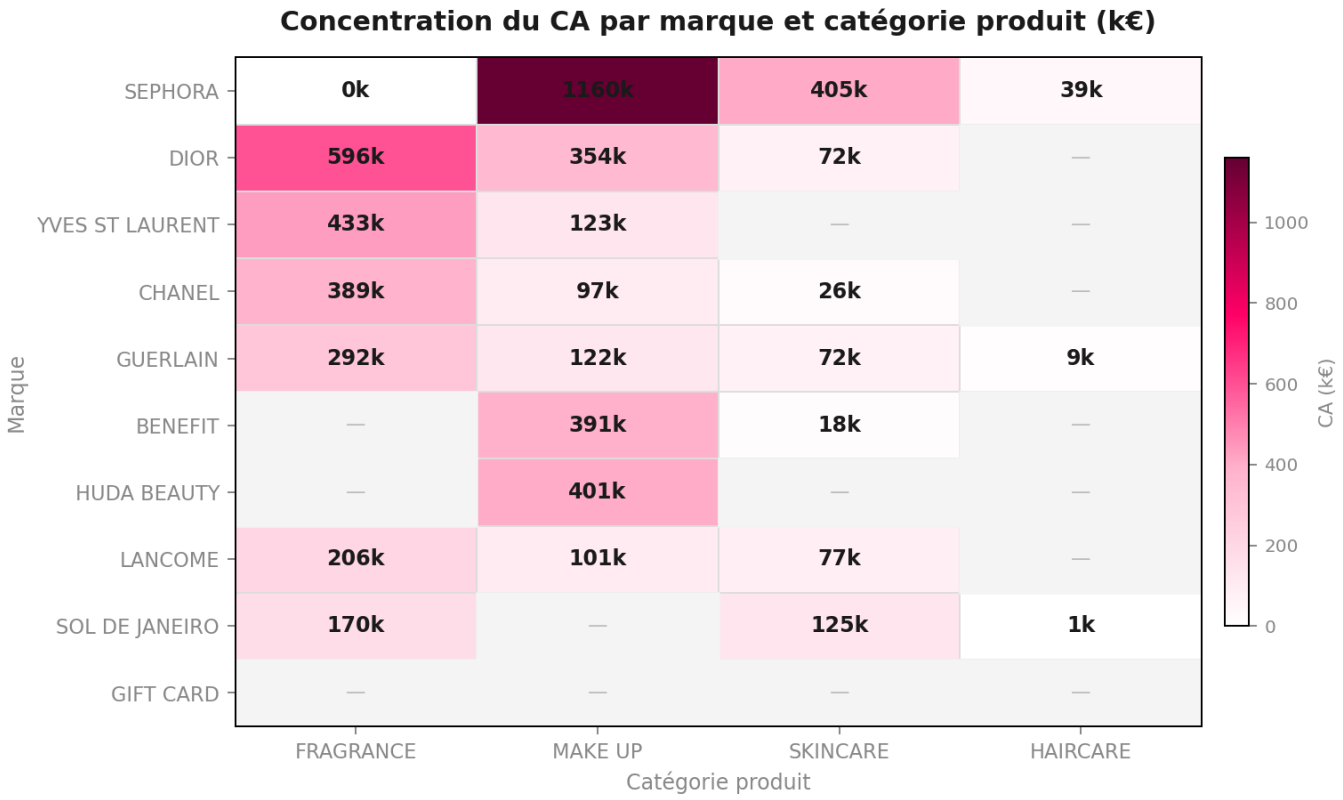
Concentration du CA par marque et catégorie produit (k€)
Marque
SEPHORA
DIOR
YVES ST LAURENT
CHANEL
GUERLAIN
BENEFIT
HUDA BEAUTY
LANCOME
SOL DE JANEIRO
GIFT CARD
FRAGRANCE
MAKE UP
SKINCARE
HAIRCARE
Catégorie produit
0k
1160k
405k
39k
596k
354k
72k
433k
123k
389k
97k
26k
292k
122k
72k
9k
391k
18k
401k
206k
101k
77k
170k
125k
1k
CA (k€)
1000
800
600
400
200
0

D Notre angle — Segmentation Dynamique Automatisée

Sephora dispose de 9 segments RFM recalculés **mensuellement**. **~12% des clients changent de comportement entre deux recalculs** — soit ~1533k EUR/mois de CA mal ciblé. Notre système détecte ces migrations **dès le prochain achat**, 30 jours plus tôt, et déclenche automatiquement la bonne action marketing.

E Pipeline d'automatisation complète

L'objectif est de livrer un système **end-to-end autonome** en 3 couches, opérable directement par les équipes data et CRM Sephora :

COUCHE	DÉCLENCHEUR	ACTION AUTOMATIQUE	RÉSULTAT
① Mise à jour du persona	Chaque nouvel achat d'un client	Recalcul incrémental des 25 features → réassignation au cluster le plus proche (MiniBatchKMeans) sans ré-entraînement	**Persona du client mis à jour en temps réel — plus de décalage mensuel**
② Ciblage pub automatique	Migration de persona détectée	Déclenchement automatique de la séquence CRM associée (email, push app, offre) selon la matrice migration → action	**Bonne communication au bon moment — ROI ciblé par type de migration**
③ Réactualisation globale des personas	À la demande Sephora (hebdo / mensuel / event)	Re-entraînement complet K-Means sur données récentes + re-profiling des personas + export nouveau modèle + dashboard mis à jour	**Personas toujours à jour selon les évolutions de marché (soldes, trends, saisons)**

F Limites du RFM statique & hypothèses détectées

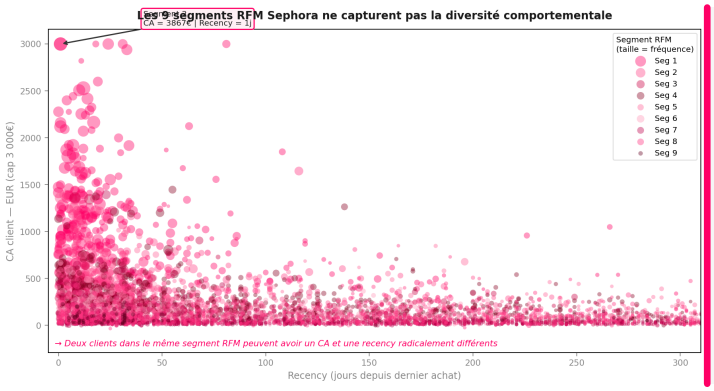

Deux clients, même segment RFM 2 — comportements opposés : CA ×10 de différence, recency opposée. Le RFM ne le détecte pas avant 30 jours.

Ce qu'on voit déjà :

- Omnicanaux : CA/client **+182%** vs mono-canal
- Hommes (7%) : panier **+37%** — achats cadeaux
- 44.7% mono-achat → fidéliser = CLV **×3.9**
- FRAGRANCE 99.9€/ticket — up-sell skincare-only
- Pic Nov-Déc = 38% du CA semestriel → saisonnalité forte

G Roadmap

Semaine	Actions	Livrable
S1 — cette semaine	Feature engineering (25 vars) · K-Means K=4→11 · Silhouette + Elbow · Profilage personas	customer_features.csv · modèle validé · personas profilés
S2	Simulation Juil–Sept (replay transactions) · Matrice migration · Sankey · Signaux précurseurs	migrations.csv · Sankey diagram · personas finalisés
S3	Pipeline automatisation (couches ①②③) · Dashboard Streamlit · Quantification ROI euros · Soutenance	Dashboard live · PDF final · présentation jury

Store vs Estore — 4 métriques comportementales (base de segmentation canal)

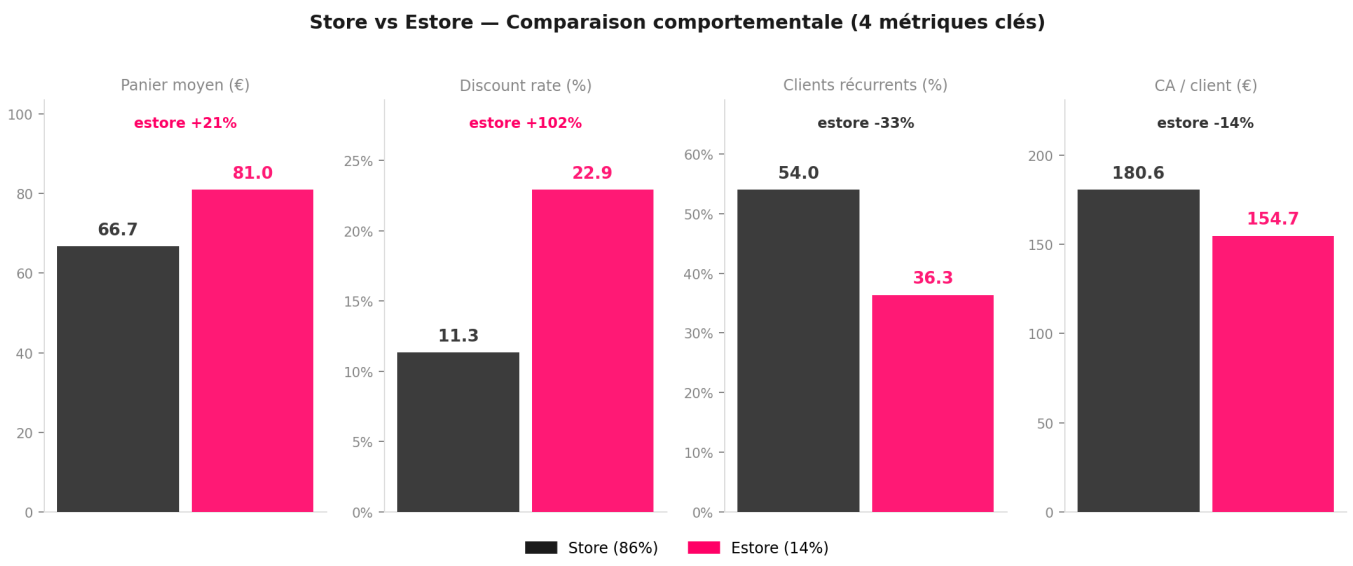
Store vs Estore — Comparaison comportementale (4 métriques clés)
Panier moyen (€)
estore +21%
66.7
81.0
Discount rate (%)
estore +102%
11.3
22.9
Clients récurrents (%)
estore -33%
54.0
36.3
CA / client (€)
estore -14%
180.6
154.7
Store (86%)
Estore (14%)